

# **Classificação de Placas de Trânsito**

Comparação de Estratégias de Deep Learning para Classificação  
de Placas de Trânsito

**Autores:** Augusto Carvalho Soares

Igor Gonçalves Ribeiro

João Paulo da Silva Eloy

PCG306D – Tóp. Esp. em I. A. 2 - Análise de Imagens e Vídeo

**Professor: Dr. Jefferson Rodrigo**

**Universidade Federal de Uberlândia**

# Classificação de Placas de Trânsito| Problema e Motivação

**Norman Bel Geddes (1939)**

- Carros elétricos controlados por rádio, impulsionados por campos eletromagnéticos

**DARPA (2004) competição**

- Veículos autônomos premiação de 1 milhão de dólares, percorrer 228 km em até 10h

**DARPA (2007) competição – grupo seletivo**

- Circuito de 90 km contendo diversos obstáculos, em rodovias
- Demonstrar para as indústria o potencial

# Classificação de Placas de Trânsito | Problema e Motivação

**Veículos Autônomos - Desafios**

**Tomar a decisão segura e precisa no momento certo**

**Reconhecimento automático de placas é essencial para sistemas de condução autônoma (ADAS)**

# Classificação de Placas de Trânsito | Problema e Motivação



# Classificação de Placas de Trânsito | Objetivos

## Objetivo principal:

Investigar e comparar o desempenho de redes MLP e CNN no dataset **GTSRB** - German Traffic Sign Recognition Benchmark.

## Objetivos específicos:

- Avaliar o impacto de 4 estratégias de平衡amento de dados no modelo MLP.
- Identificar a arquitetura (MLP vs. CNN) mais robusta para esta tarefa.
- Utilizar otimização automática de hiperparâmetros (Optuna) para uma comparação justa.
- Confirmar a capacidade das CNNs em capturar padrões espaciais.

# Classificação de Placas de Trânsito | Caracterização dos Dados

**Fonte:** German Traffic Sign Recognition Benchmark (GTSRB).

**Volume:** 39.209 imagens.

**Classes:** 43 classes distintas (limites de velocidade, advertências, etc.).

**Desafio:** Desbalanceamento de classes (ex: de 210 a 2.250 amostras por classe).



Speed limit  
(20km/h)



Speed limit  
(70km/h)



Speed limit  
(100km/h)



No passing



Pedestrian s



Stop



Vehicles >  
3.5t  
prohibited



Slippery  
road



Road work



Traffic  
signals



Go straight  
or right



Roundabou  
t  
mandatory



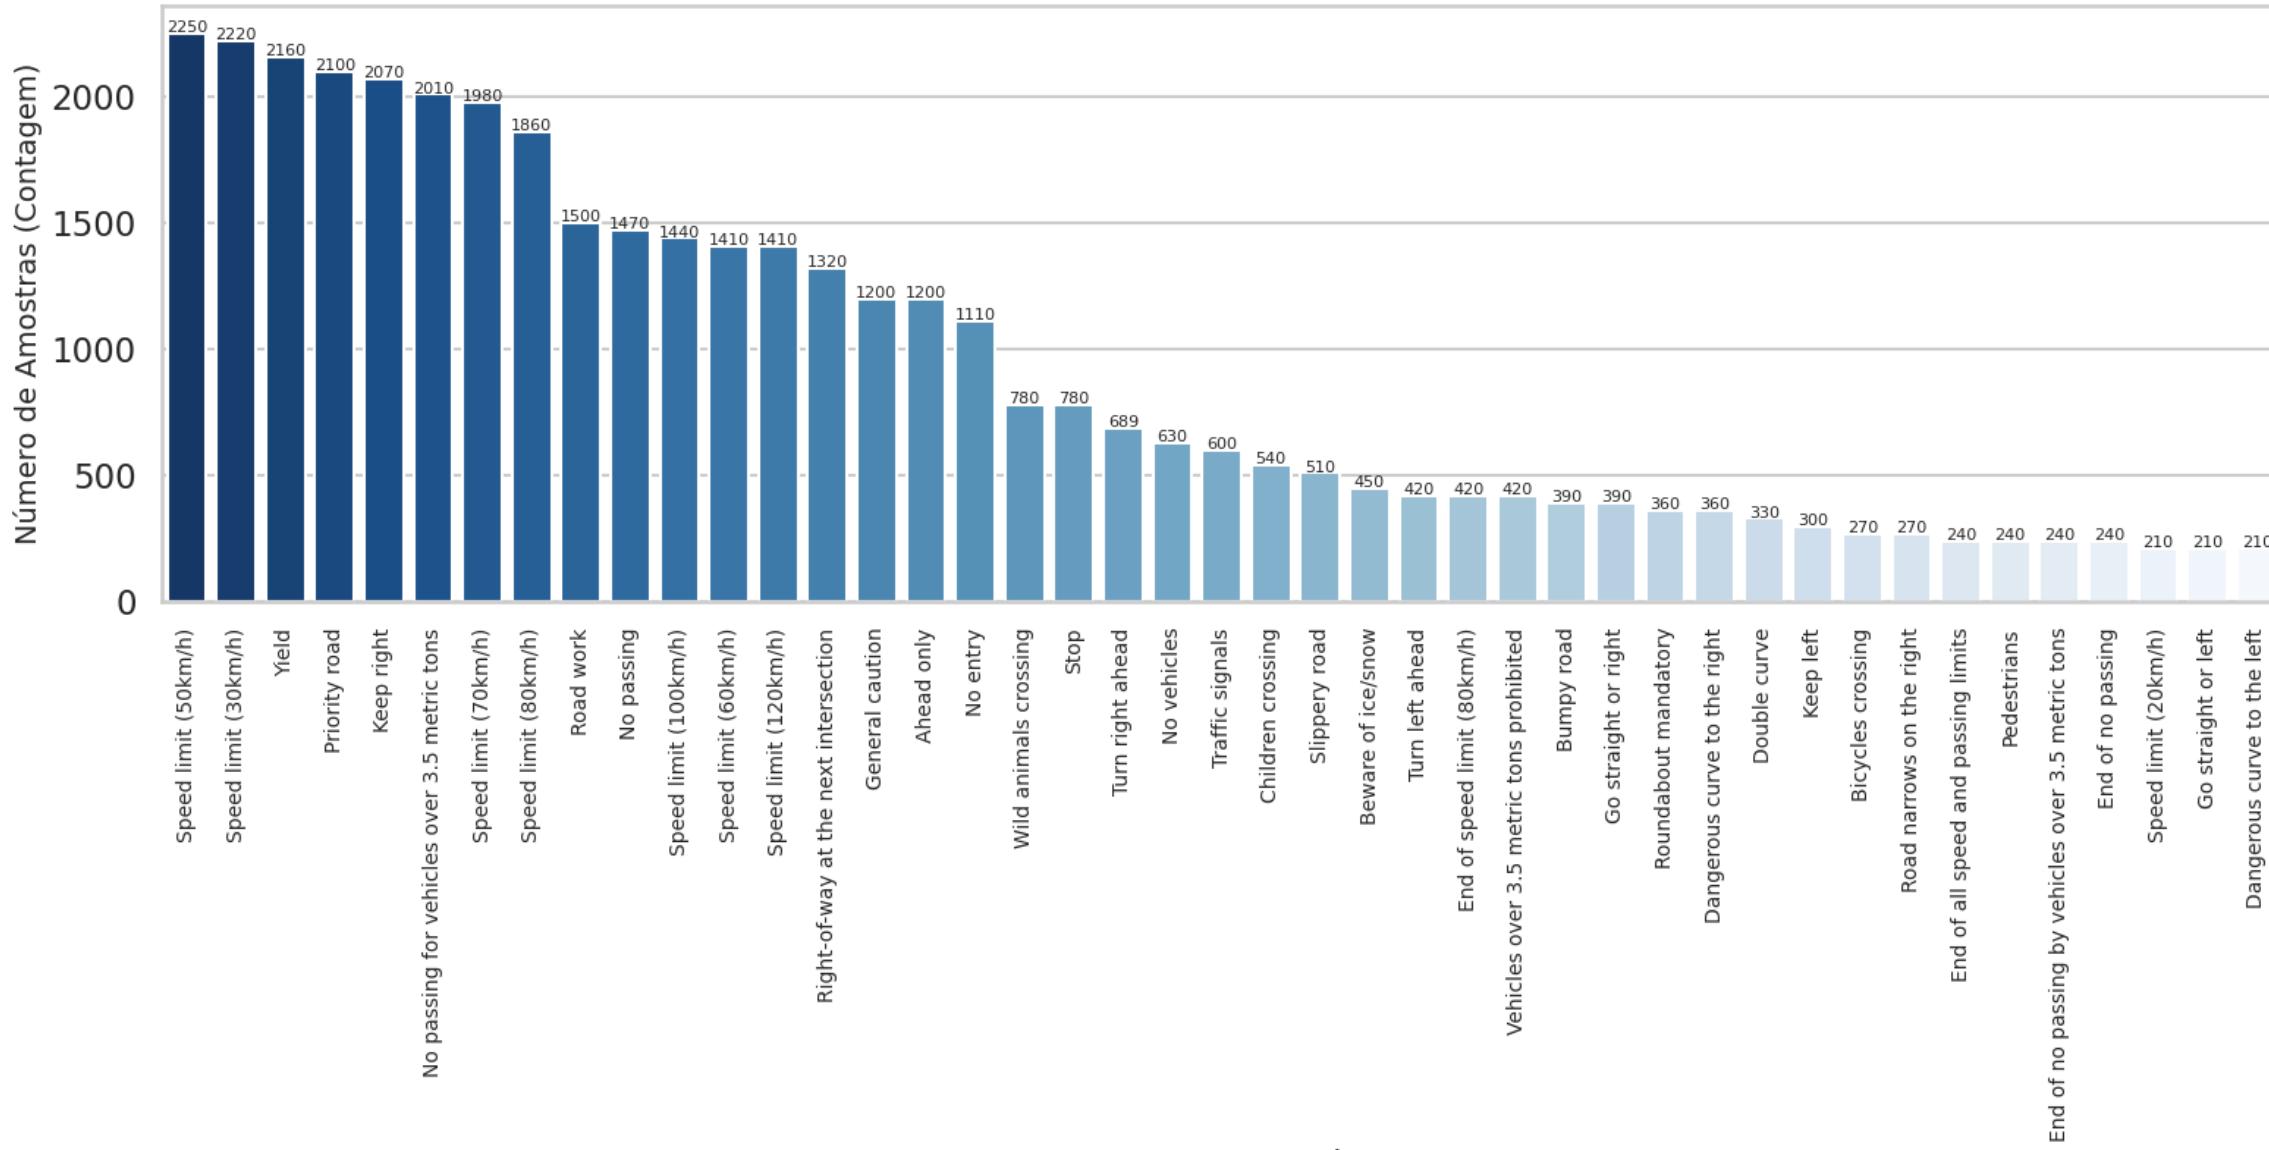
Wild  
animals  
crossing



Bicycles  
crossing

# Classificação de Placas de Trânsito | Caracterização dos

## Desbalanceamento de Classes no Dataset GTSRB



# Classificação de Placas de Trânsito | Metodologia

## Arquiteturas:

- Multilayer Perceptron (MLP)
- Convolutional Neural Network (CNN)

## Otimização

- **Optuna:** Busca automatizada de hiperparâmetros (24 *trials* por cenário).
- **Treino:** 40 épocas

## Estratégias de Balanceamento

- Sem Balanceamento (Baseline)
- Downsampling (Subamostragem)
- Upsampling (Data Augmentation)
- Híbrido (Up/Down na Mediana)

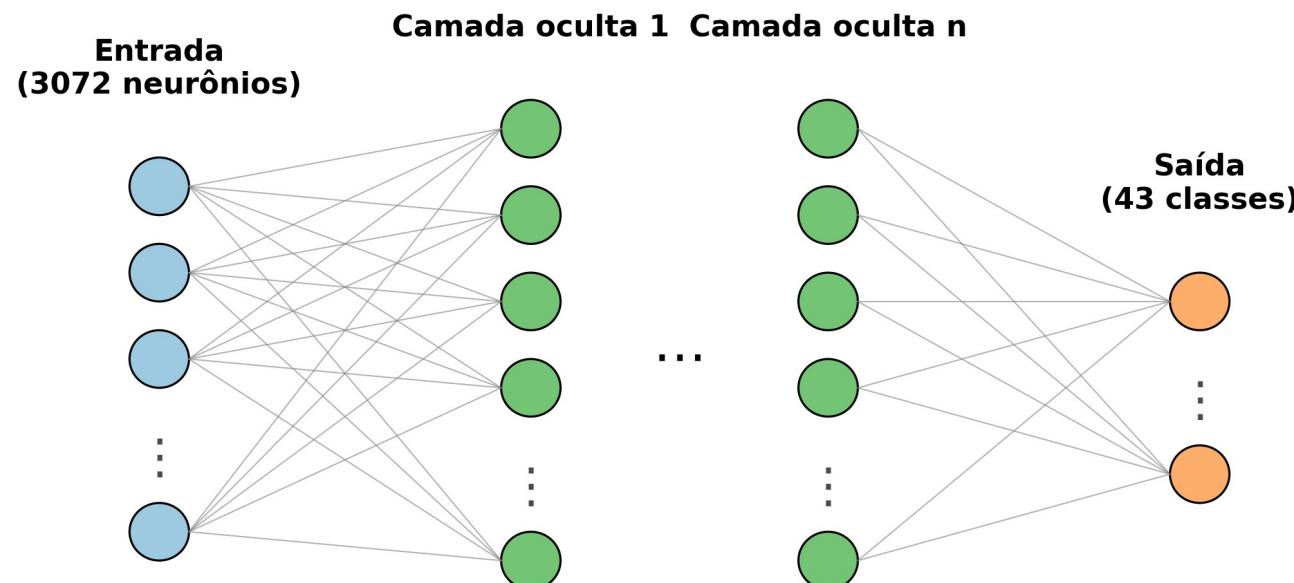
# Classificação de Placas de Trânsito | Arquiteturas

## Multilayer Perceptron (MLP)

Camada de entrada:  
valores normalizados  
dos pixels ( $32 \times 32 \times 3$ )

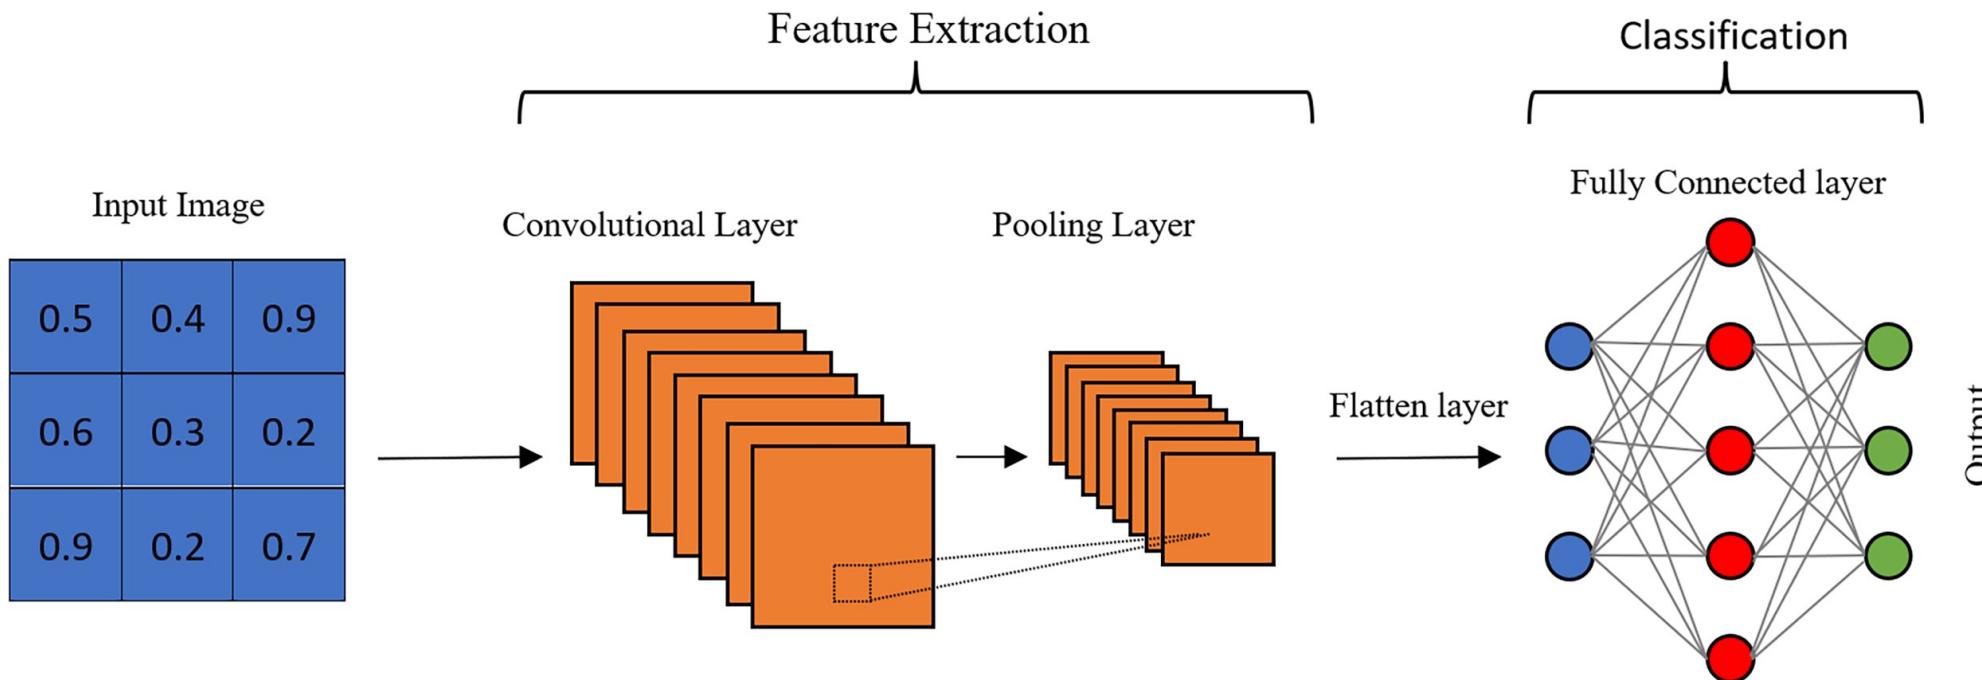
Camadas ocultas:  
quantidade variável (1-4)  
ativação ReLU/Sigmoid,  
dropout variável

Camada de saída:  
função Softmax  
(43 classes)



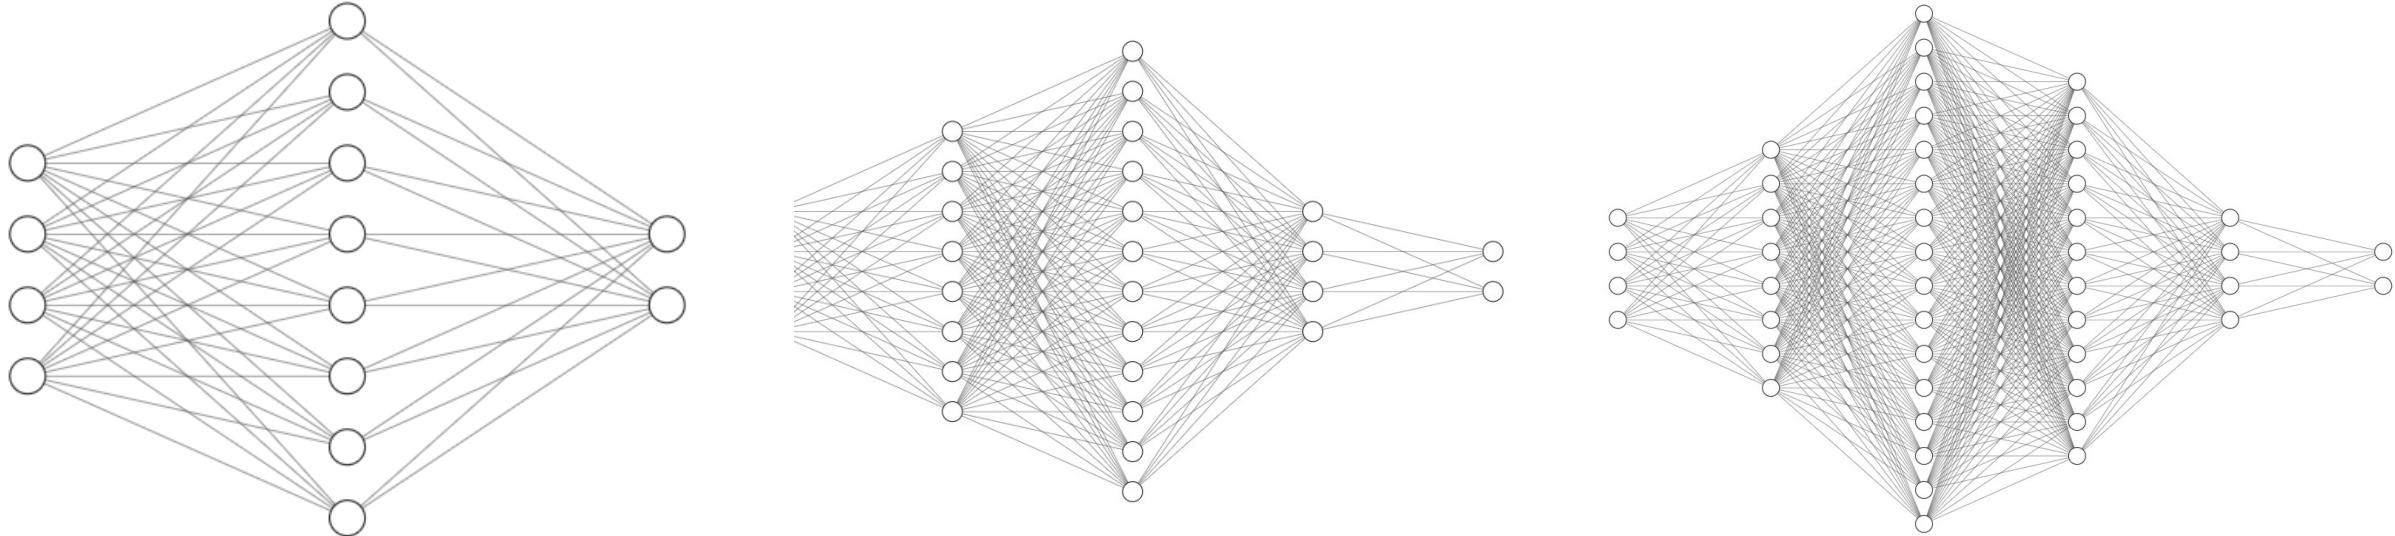
# Classificação de Placas de Trânsito | Arquiteturas

## Convolutional Neural Network (CNN)



# Classificação de Placas de Trânsito | Otimização

## Busca de hiperparâmetros



# Classificação de Placas de Trânsito | Otimização

## Busca de hiperparâmetros

100%  
Dataset Original

70%  
Treino \*

30%  
Teste

# Classificação de Placas de Trânsito | Otimização

## Busca de hiperparâmetros

100%  
Dataset Original

70%  
Treino \*

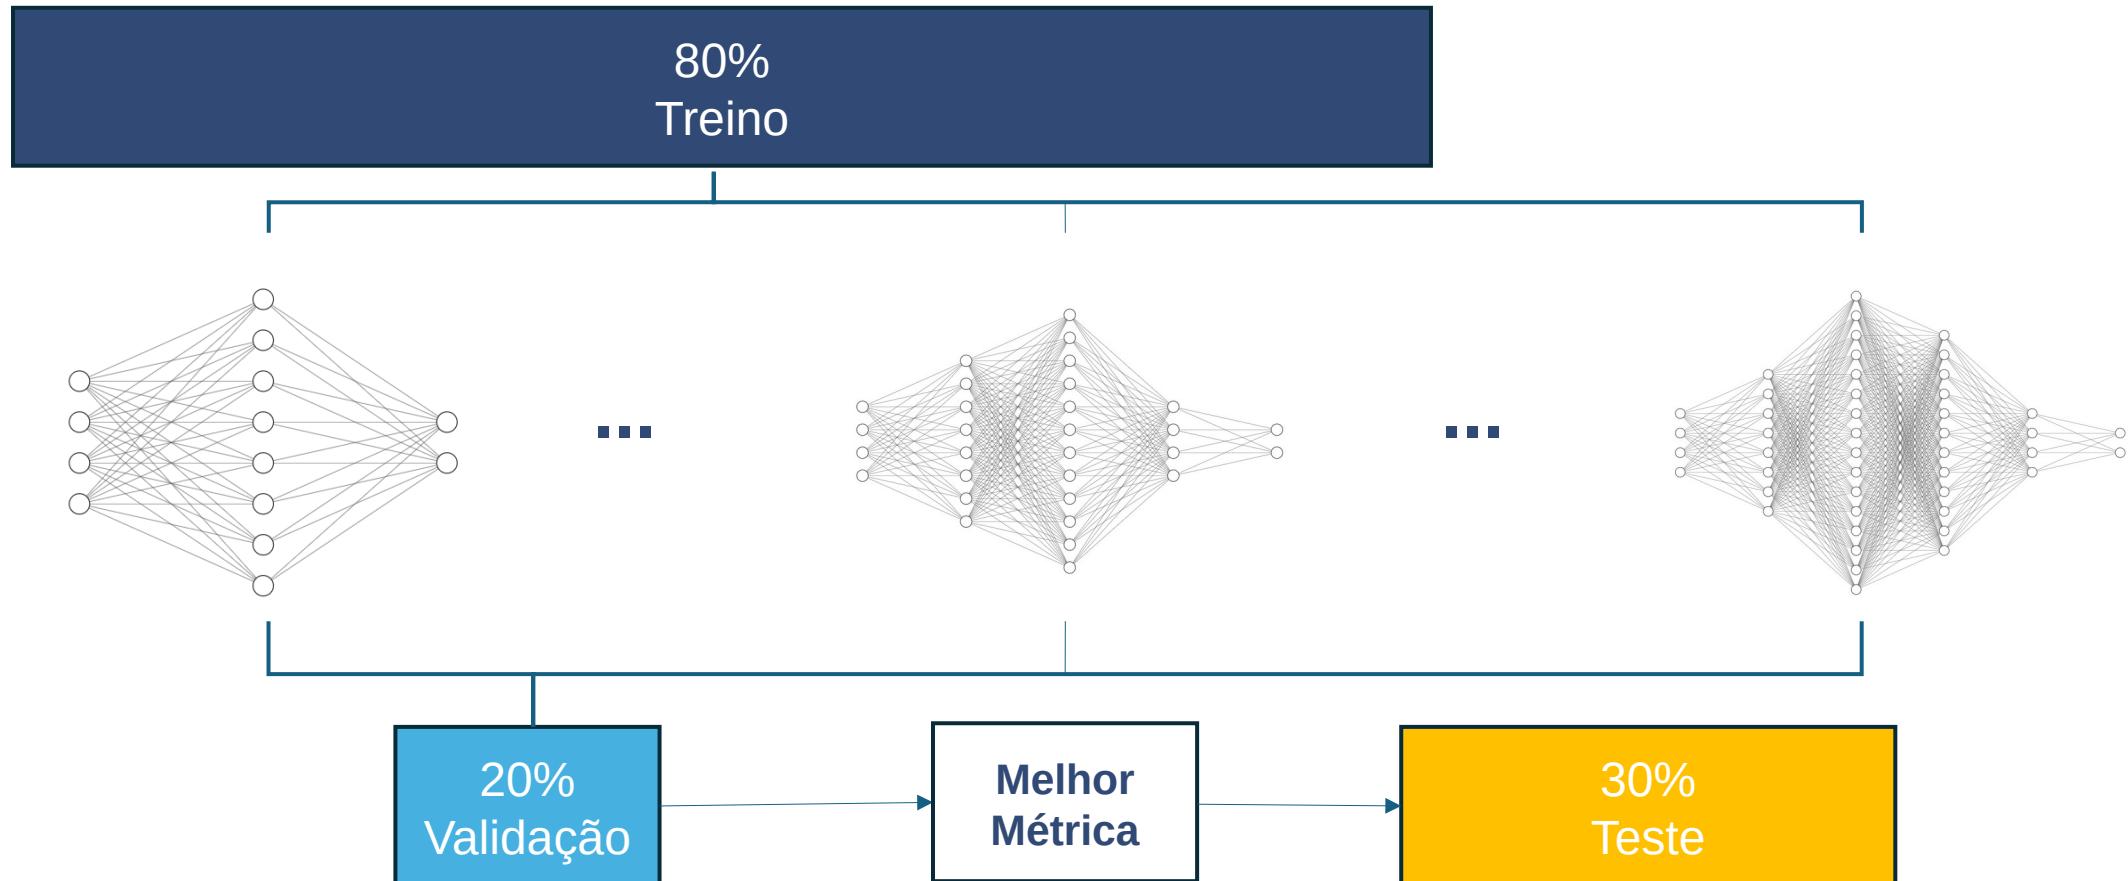
30%  
Teste

80%  
Treino

20%  
Validação

# Classificação de Placas de Trânsito | Otimização

## Busca de hiperparâmetros



# Classificação de Placas de Trânsito | Balanceamento

## Subamostragem

- Aleatório
- Balanceamento completo – Redução até a classe minoritária



...



# Classificação de Placas de Trânsito | Balanceamento

## Subamostragem

- Aleatório
- Balanceamento completo – Redução até a classe minoritária



...



# Classificação de Placas de Trânsito | Balanceamento

## Subamostragem

- Aleatório
- Balanceamento completo – Redução até a classe minoritária

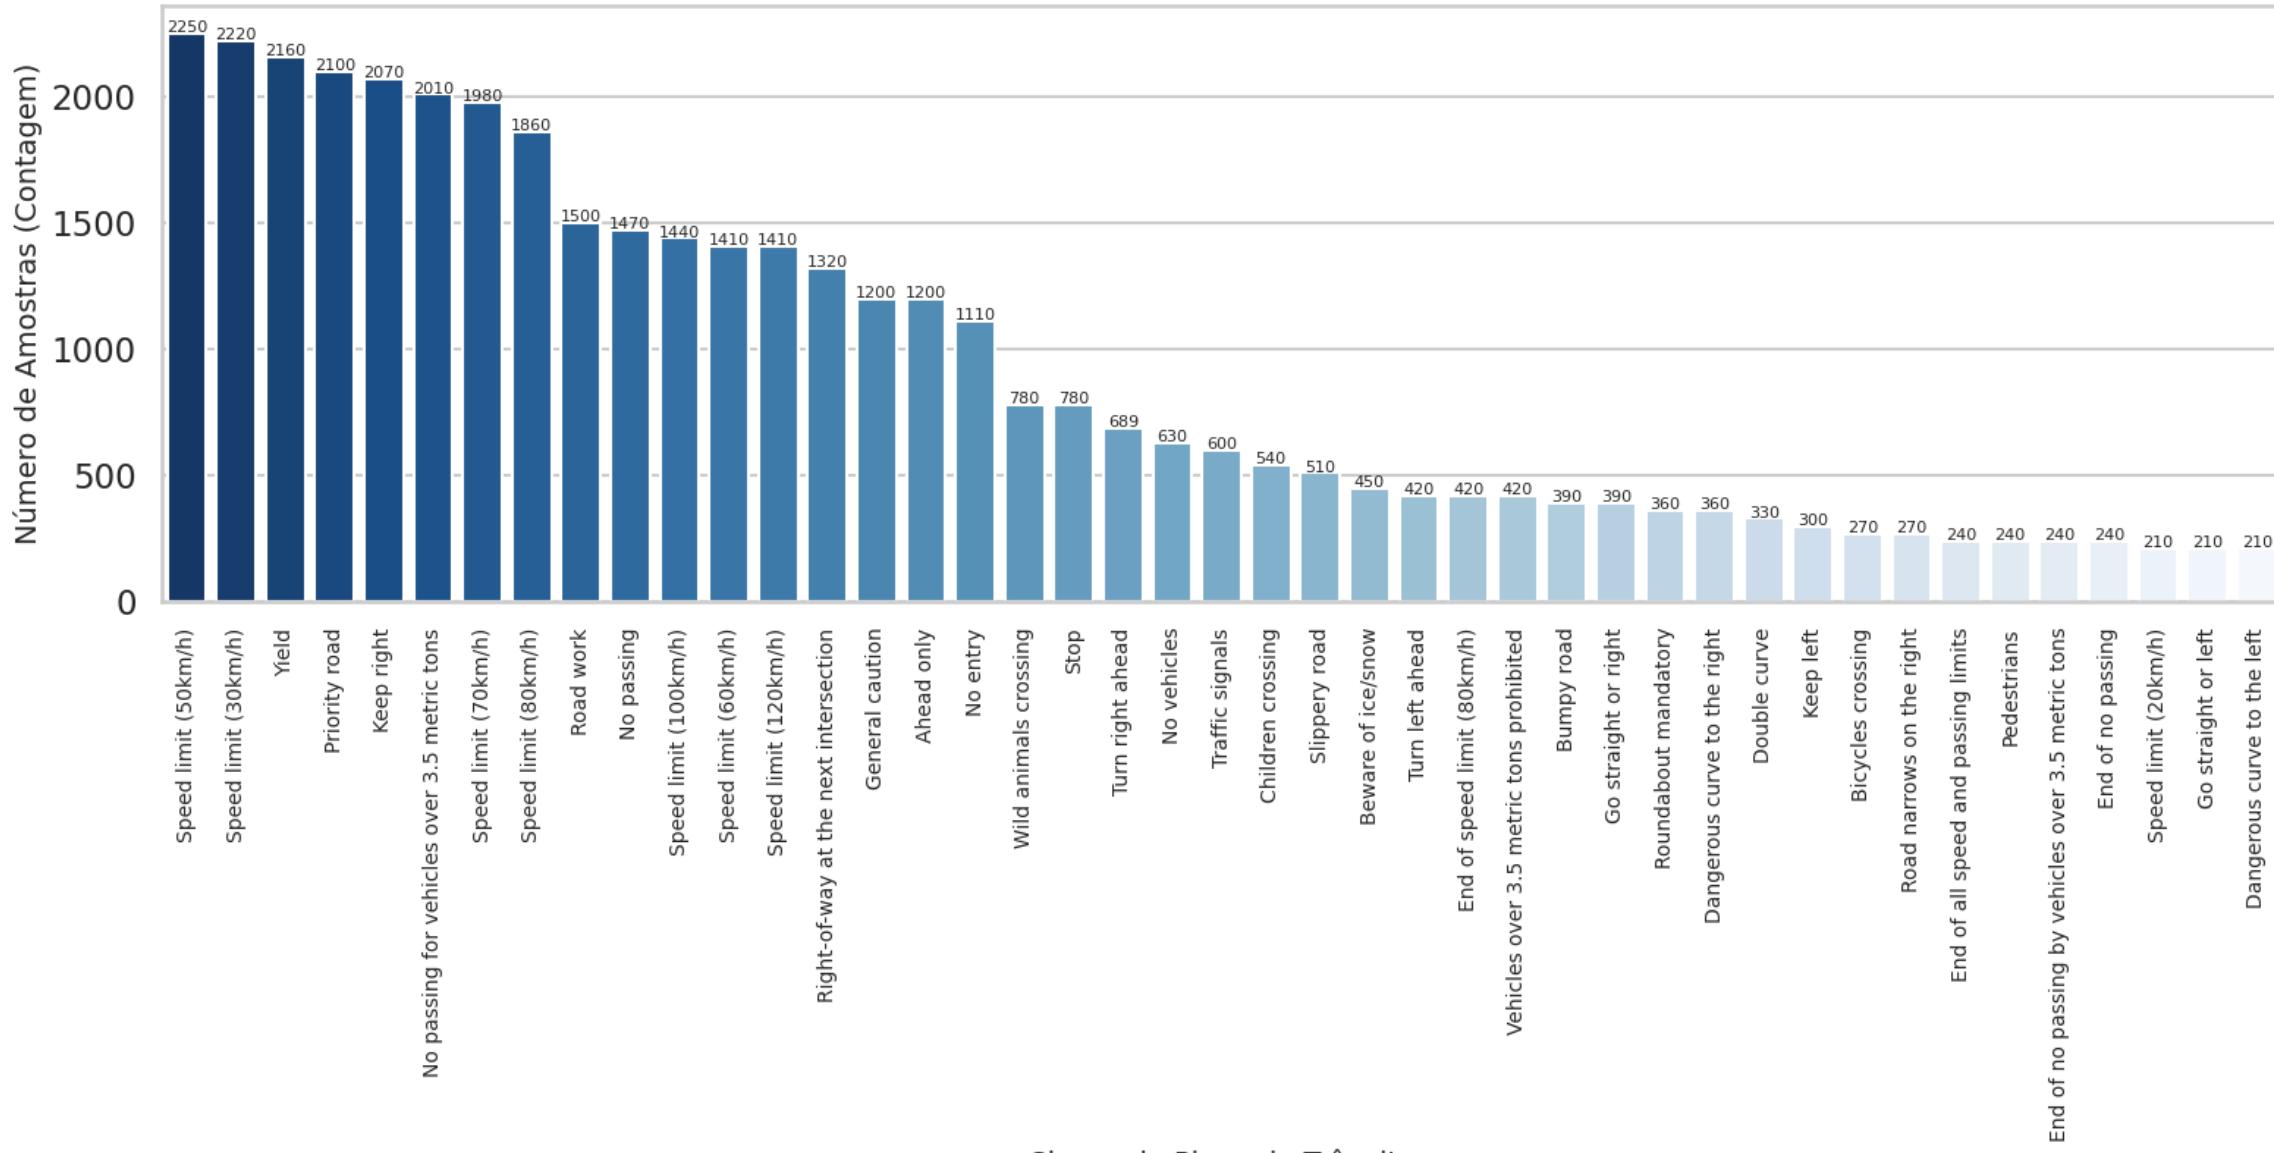


...



# Classificação de Placas de Trânsito | Balanceamento

Desbalanceamento de Classes no Dataset GTSRB



# Classificação de Placas de Trânsito | Balanceamento

## Sobreamostragem

- Aleatório
- Data Augmentation



...



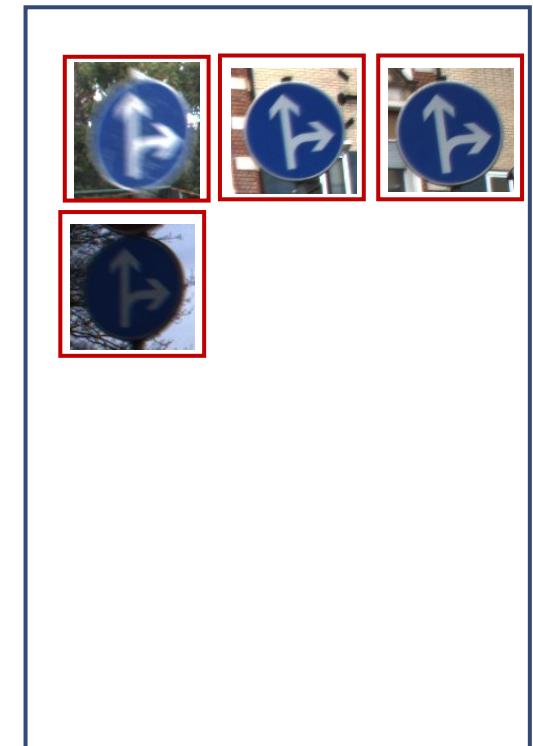
# Classificação de Placas de Trânsito | Balanceamento

## Sobreamostragem

- Aleatório
- Data Augmentation



...



# Classificação de Placas de Trânsito | Balanceamento

## Sobreamostragem

- Aleatório
- Data Augmentation

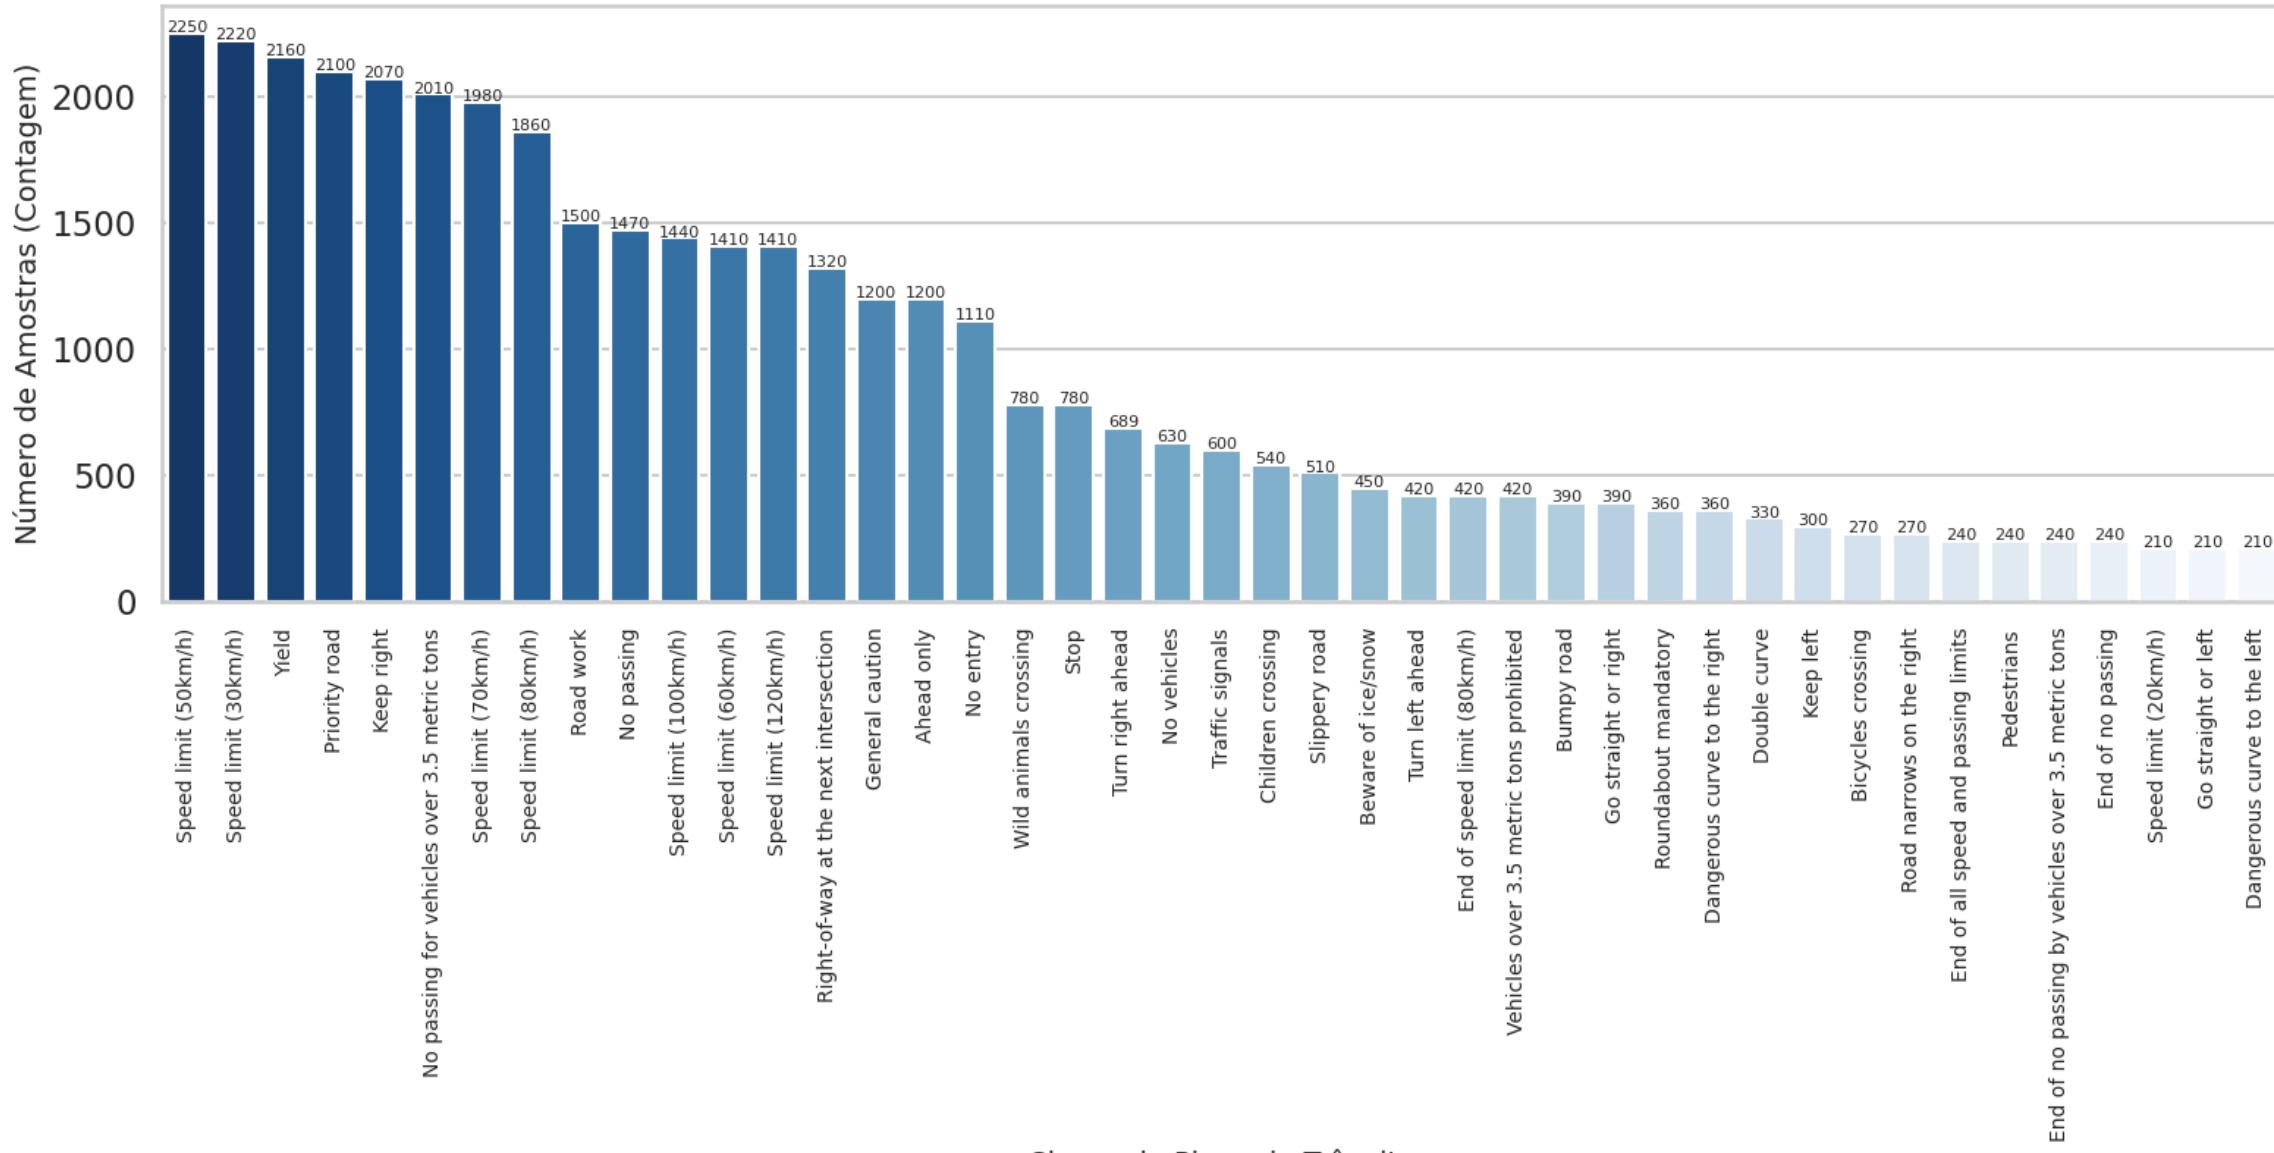


...



# Classificação de Placas de Trânsito | Balanceamento

Desbalanceamento de Classes no Dataset GTSRB



# Classificação de Placas de Trânsito | Balanceamento

## Sobreamostragem + Subamostragem

- Mediana



...

# Classificação de Placas de Trânsito | Balanceamento

## Sobreamostragem + Subamostragem

- Mediana

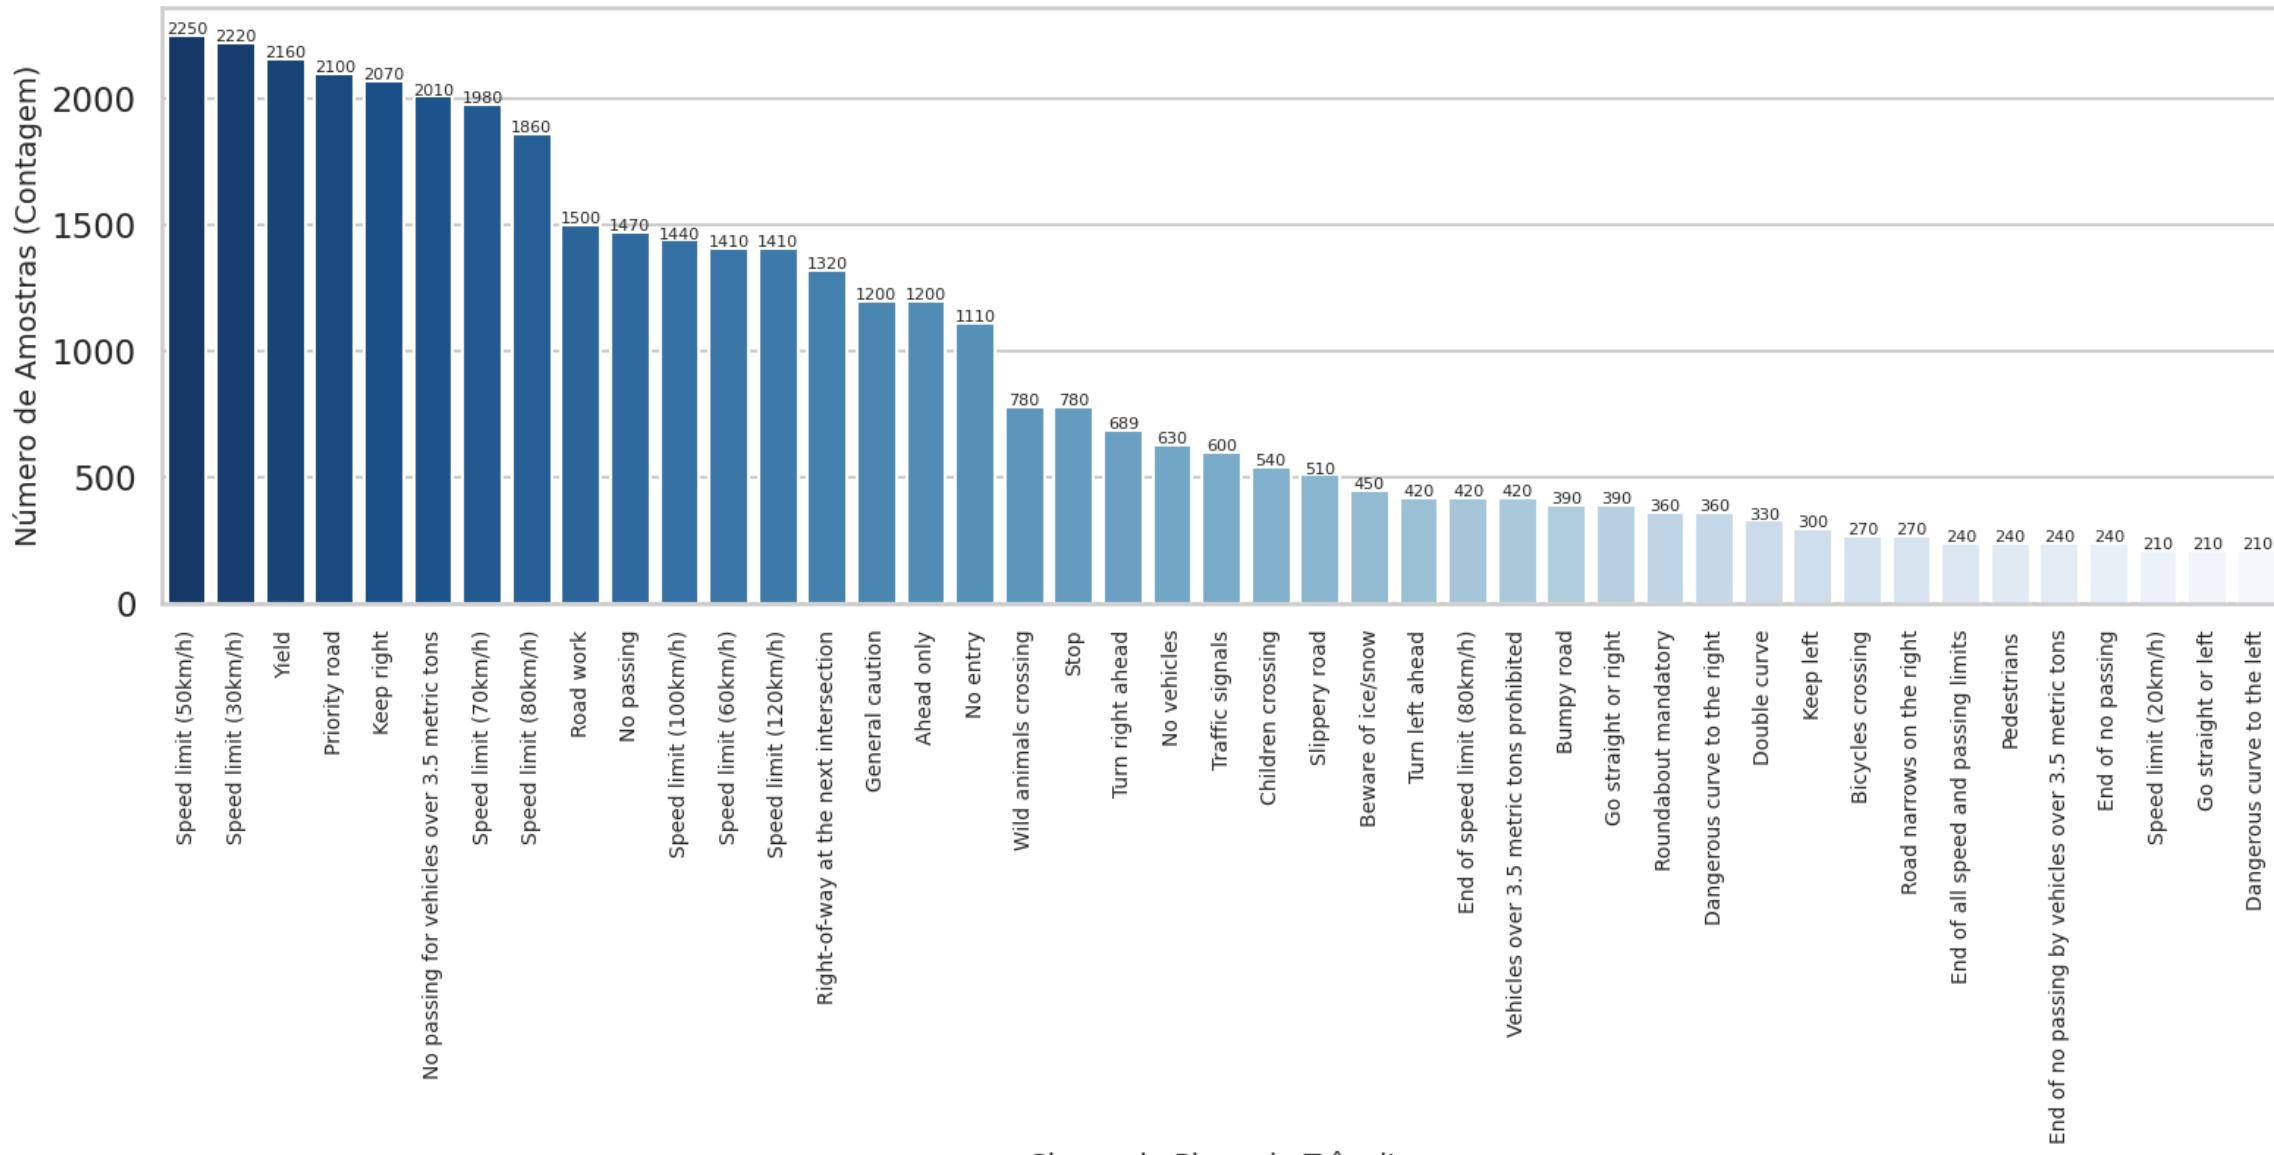


...



# Classificação de Placas de Trânsito | Balanceamento

Desbalanceamento de Classes no Dataset GTSRB



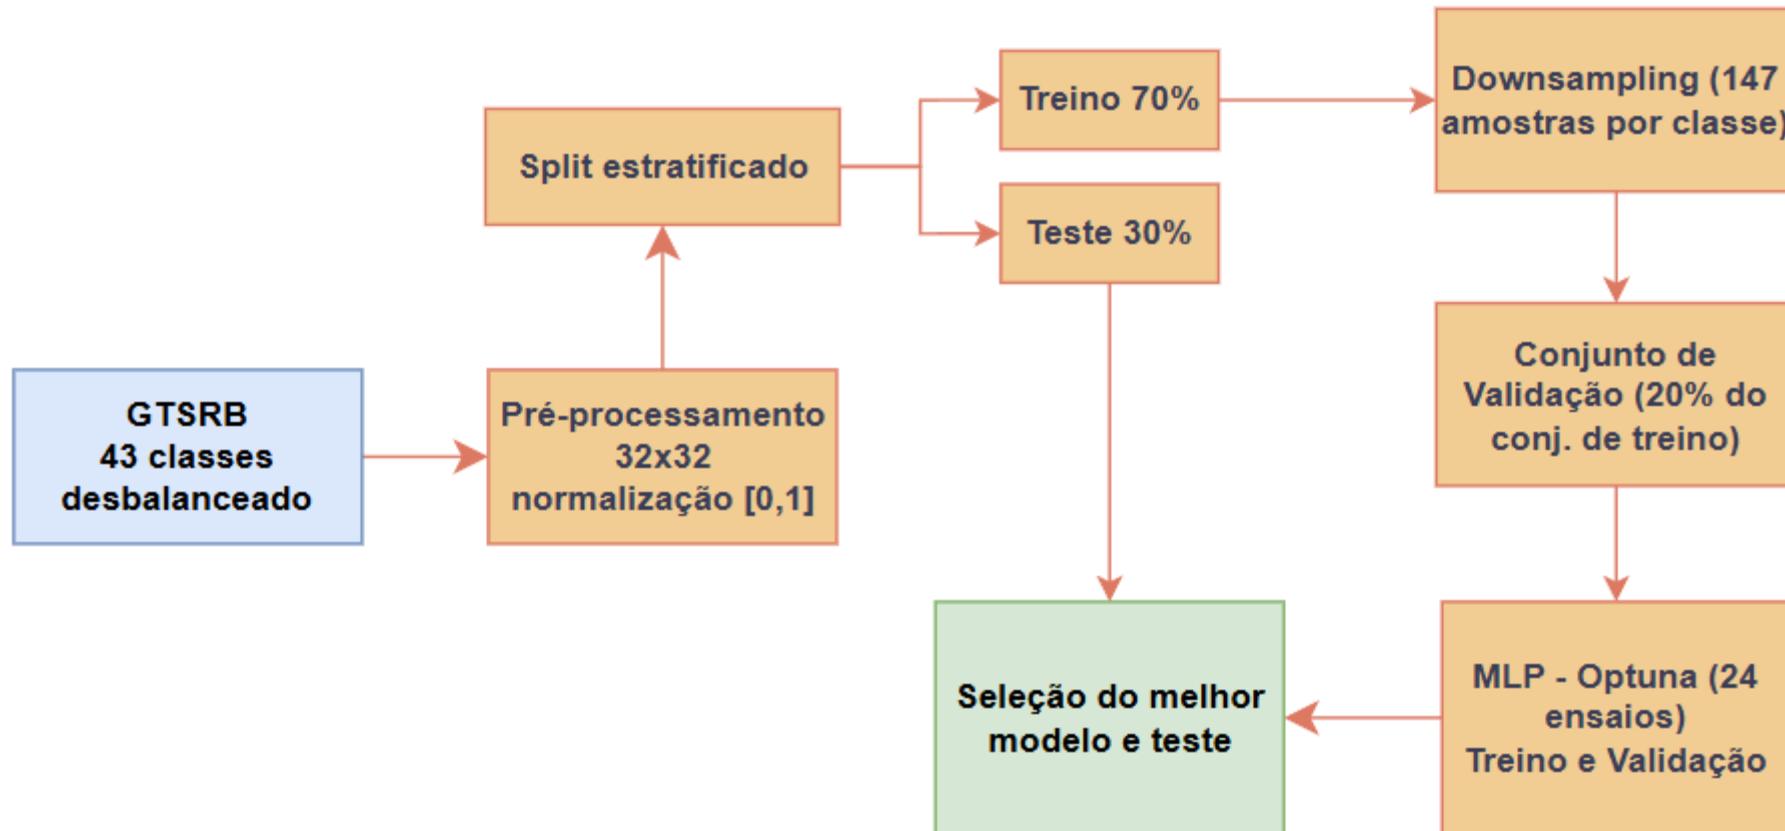
# Classificação de Placas de Trânsito | Experimentos

## MLPs sem balanceamento de dados



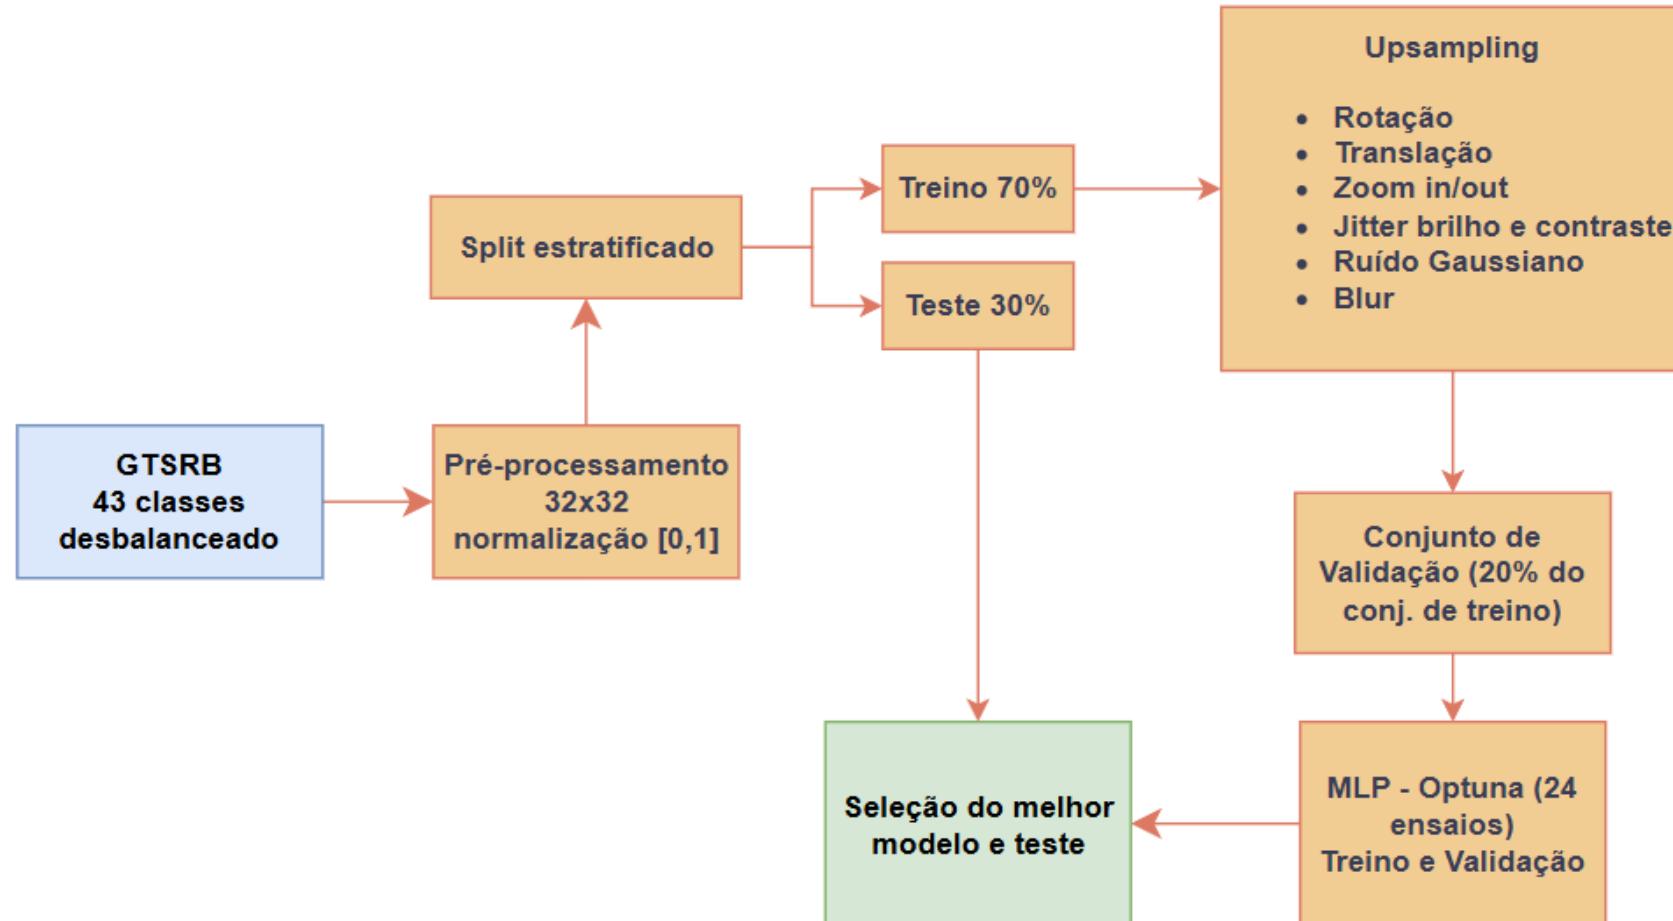
# Classificação de Placas de Trânsito | Experimentos

## MLPs com subamostragem



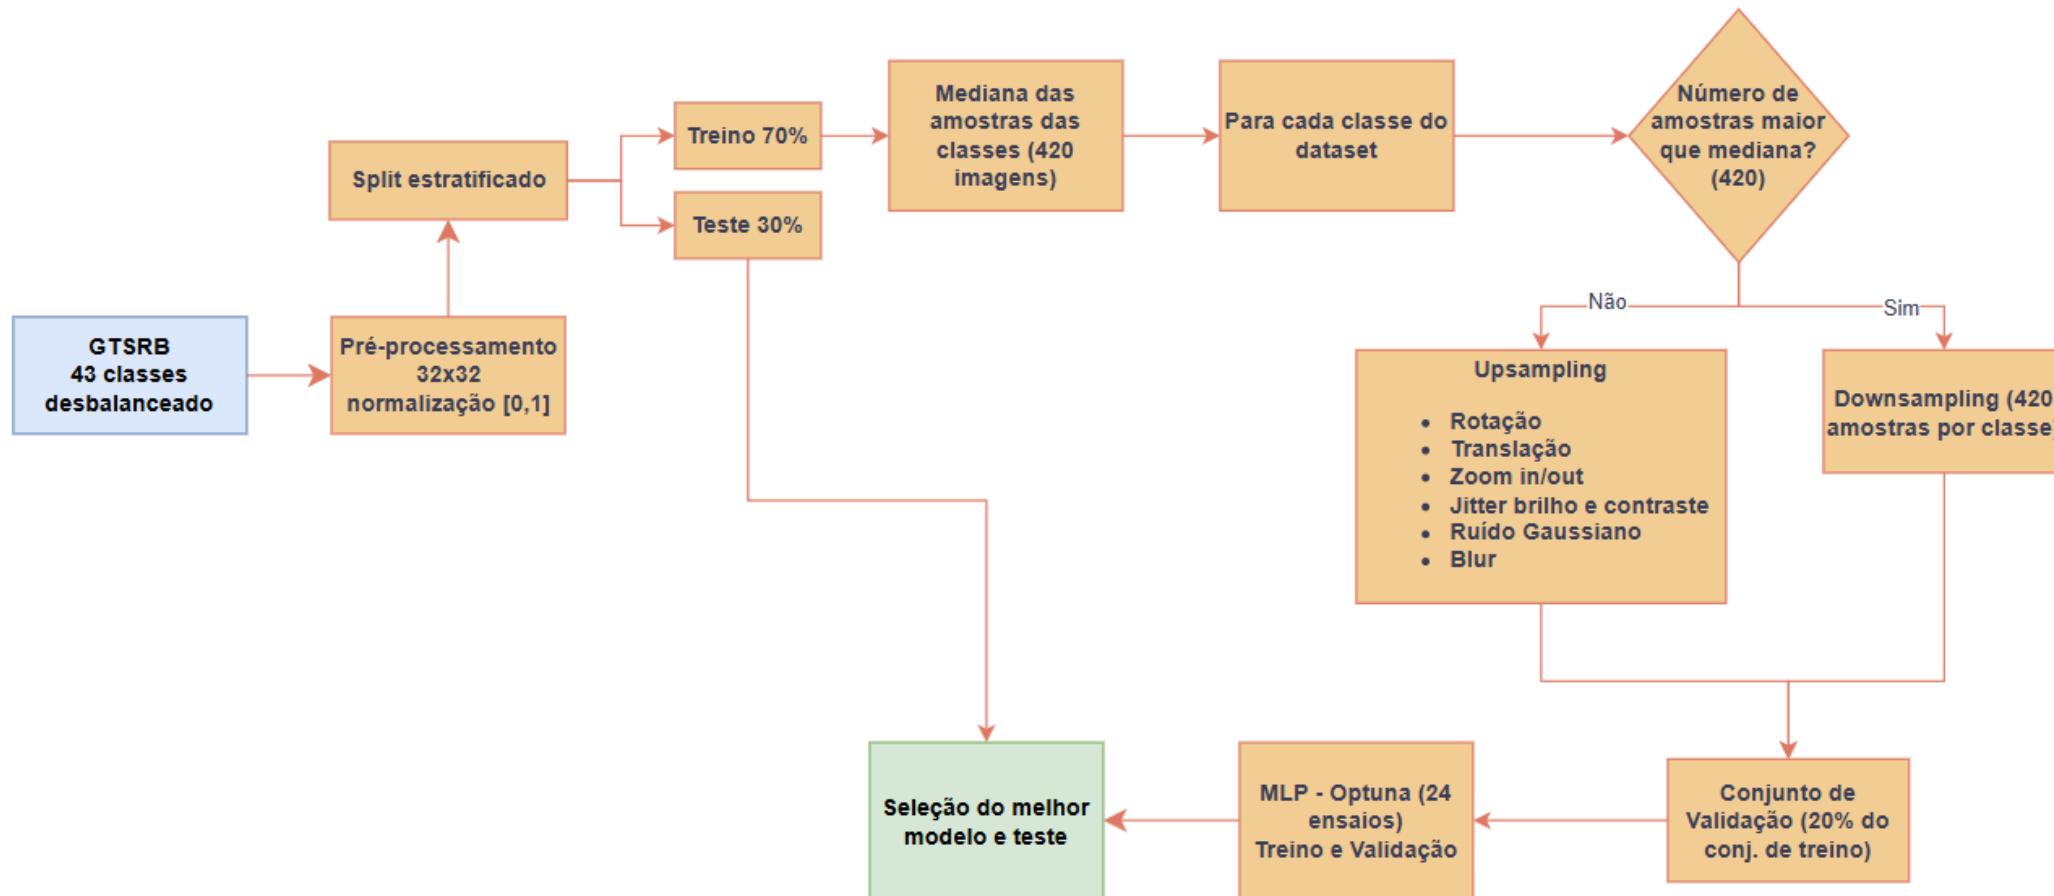
# Classificação de Placas de Trânsito | Experimentos

## MLPs com sobreamostragem



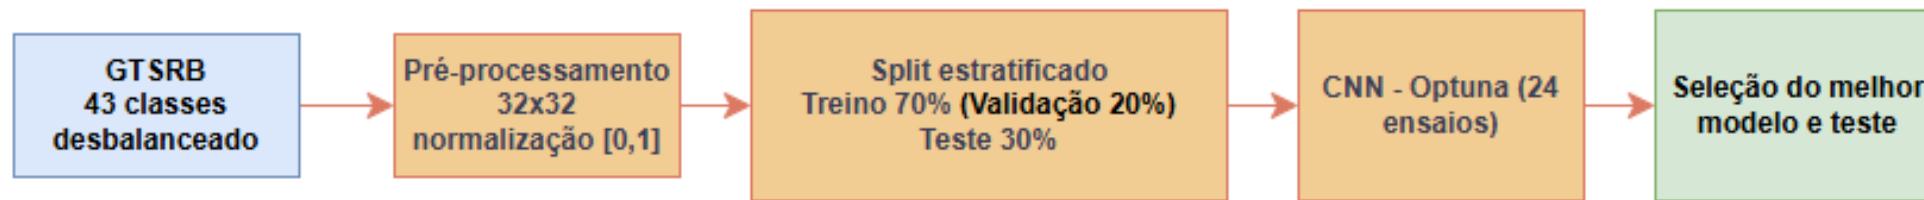
# Classificação de Placas de Trânsito | Experimentos

## MLPs com subamostragem + sobreamostragem



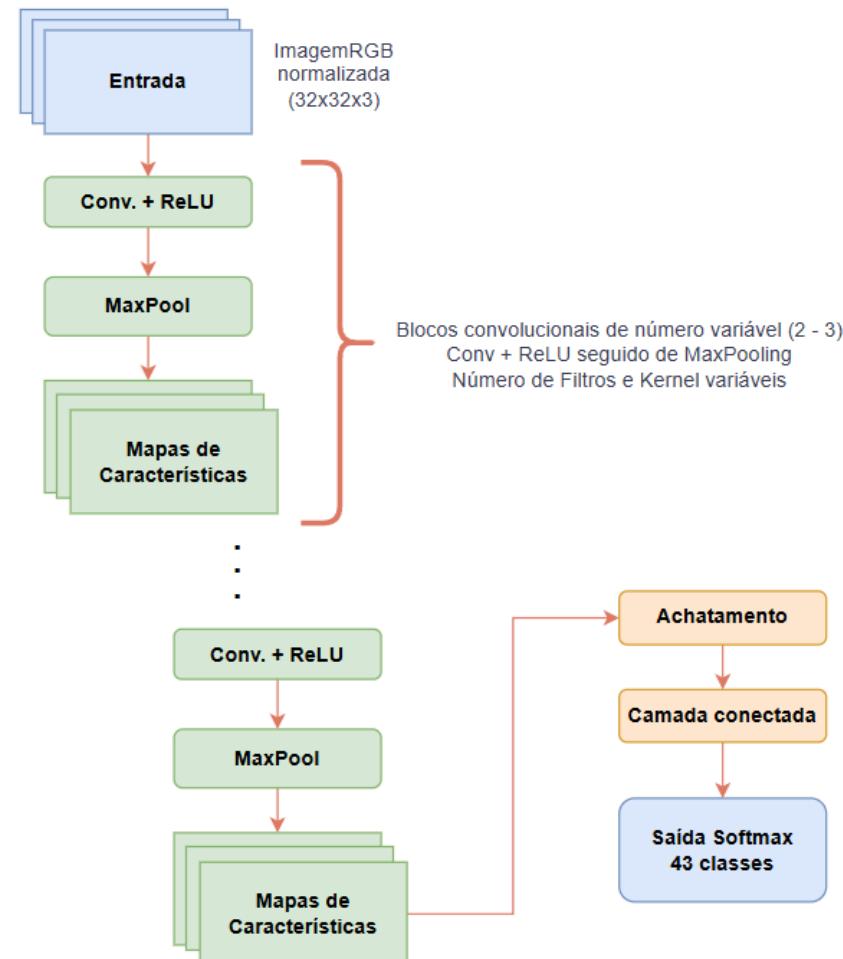
# Classificação de Placas de Trânsito | Experimentos

CNN sem técnicas de balanceamento.



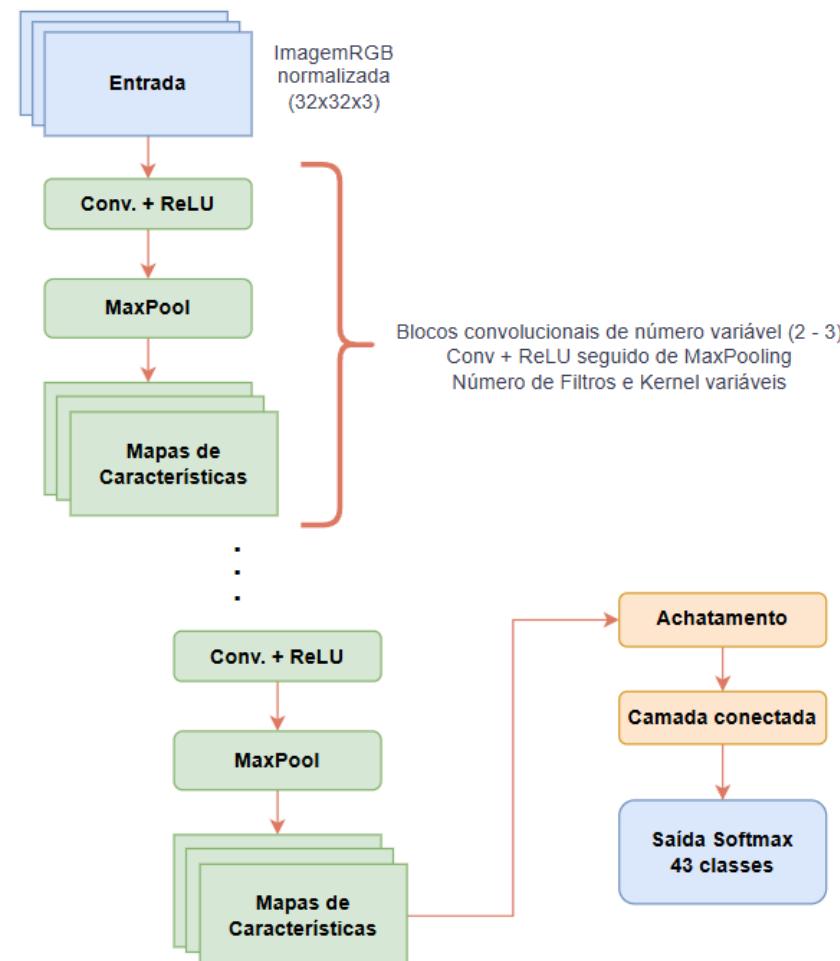
# Classificação de Placas de Trânsito | Experimentos

CNN sem técnicas de balanceamento.



# Classificação de Placas de Trânsito | Resultados

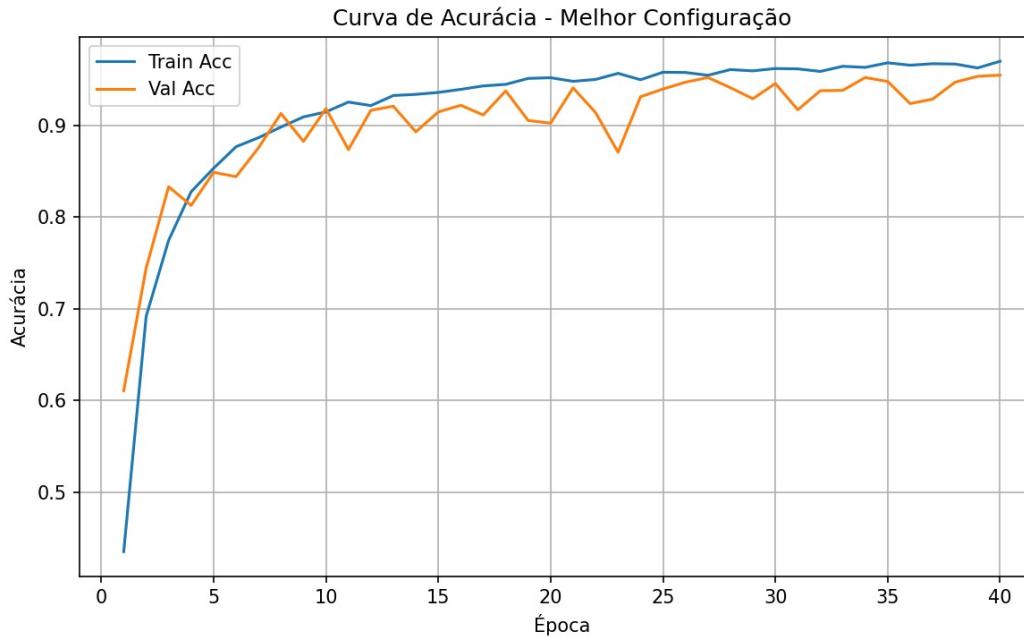
CNN sem técnicas de balanceamento.



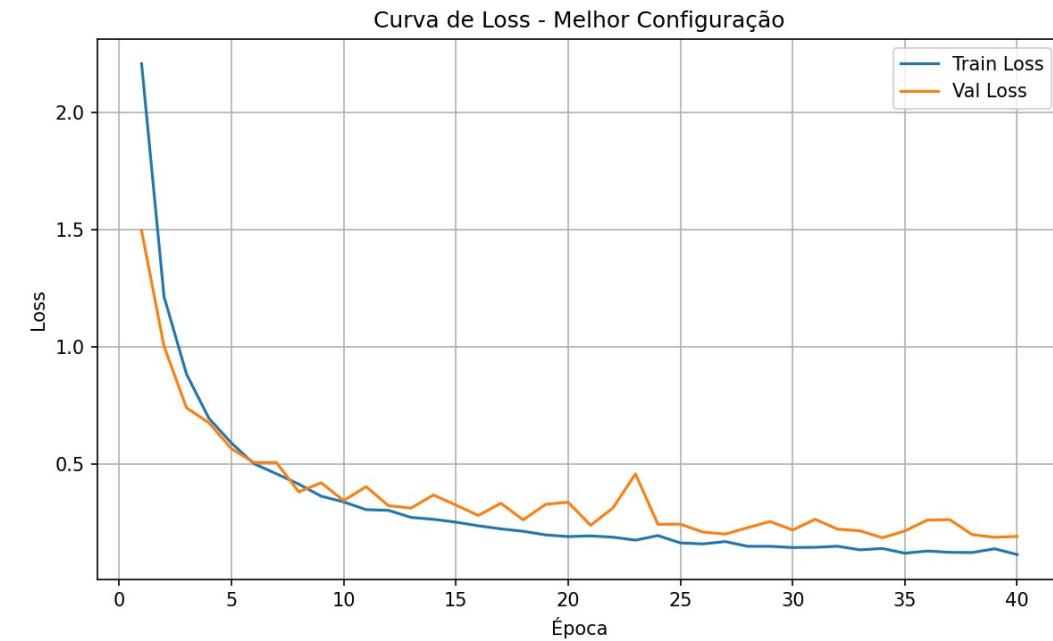
# Classificação de Placas de Trânsito | Resultados

## MLPs sem balanceamento de dados

Acurácia



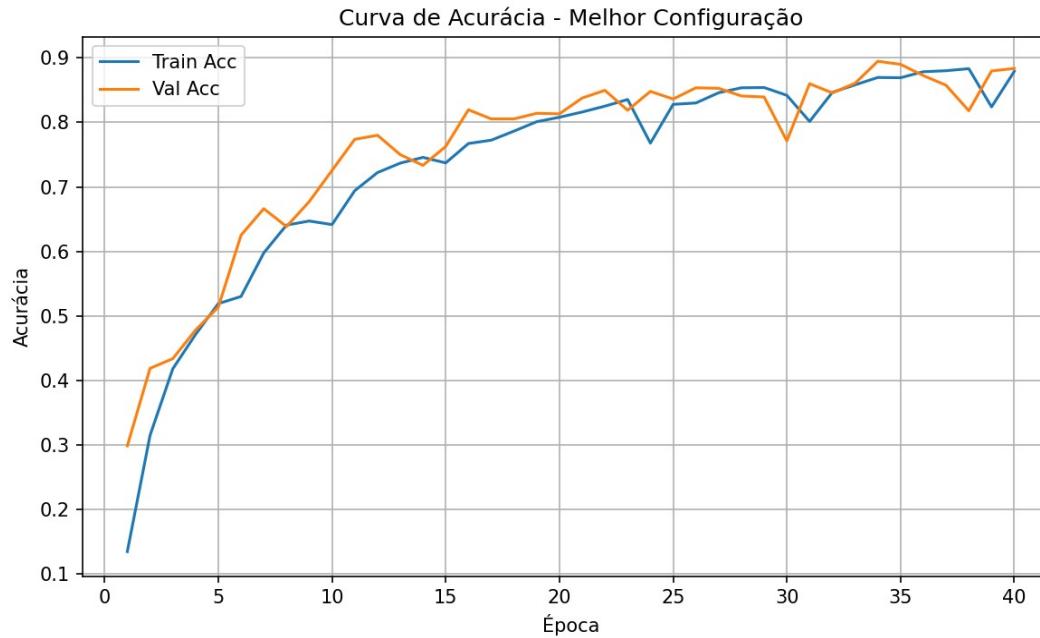
Loss



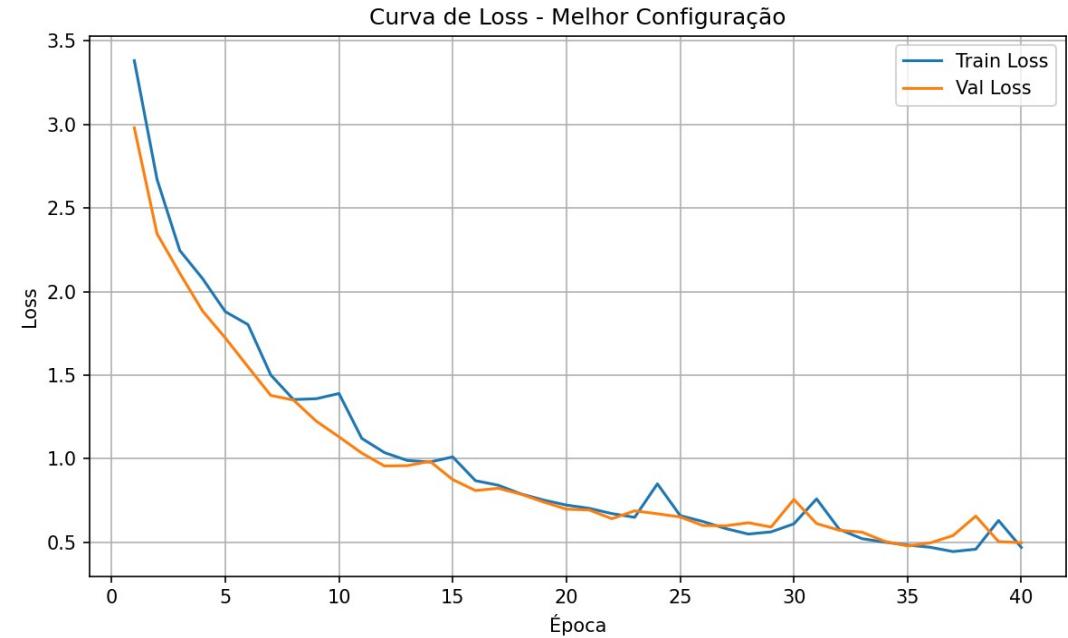
# Classificação de Placas de Trânsito | Resultados

## MLPs com subamostragem

Acurácia



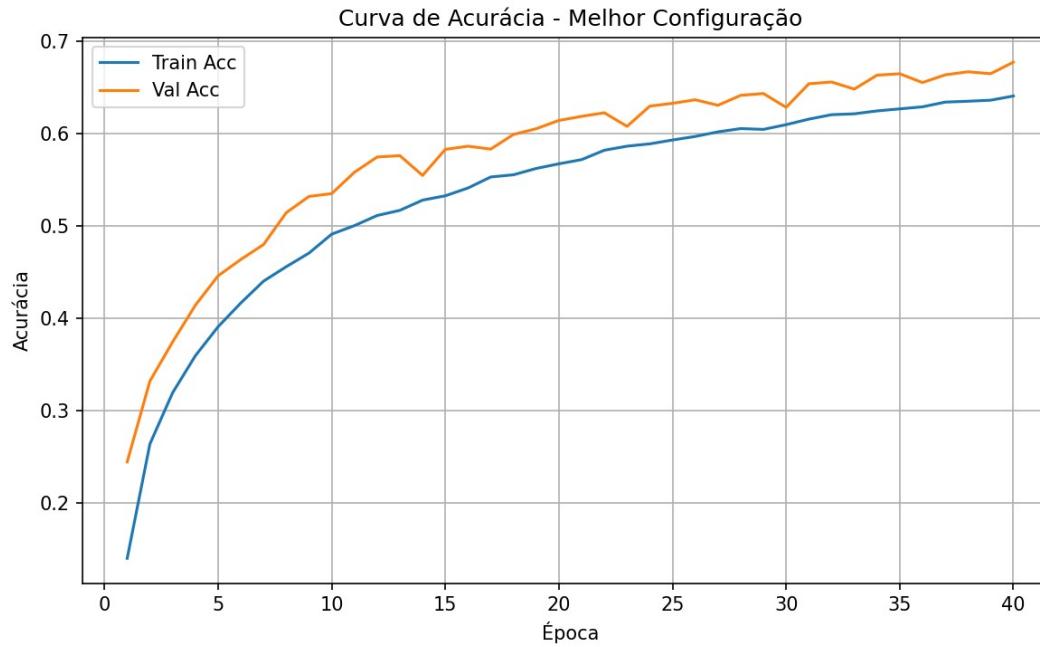
Loss



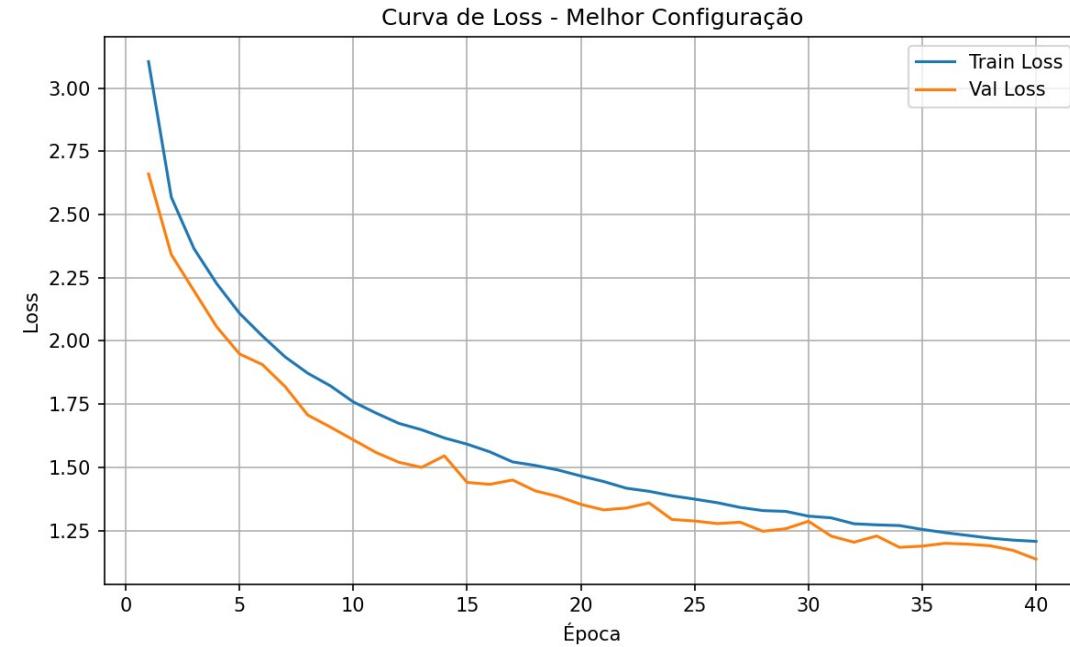
# Classificação de Placas de Trânsito | Resultados

## MLPs com sobreamostragem

Acurácia



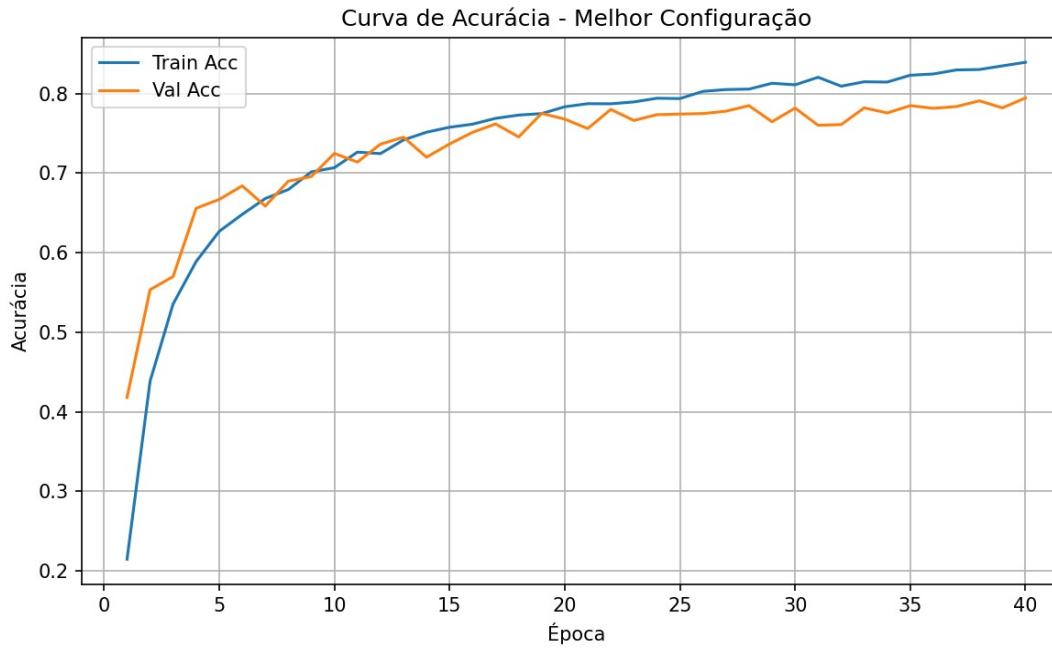
Loss



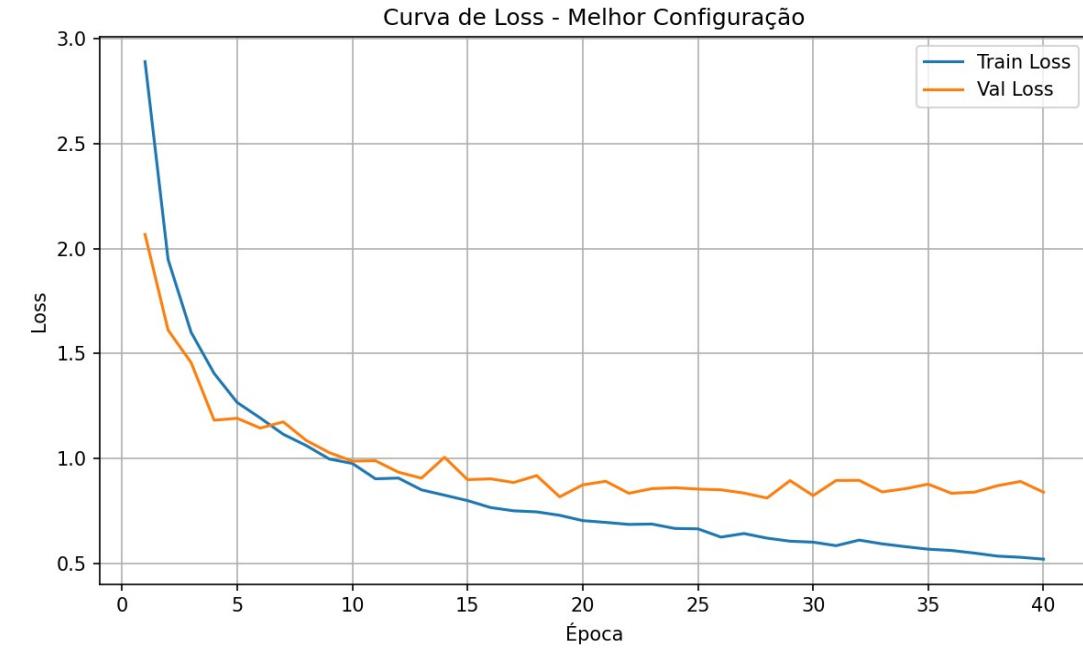
# Classificação de Placas de Trânsito | Resultados

## MLPs com subamostragem + sobreamostragem

Acurácia



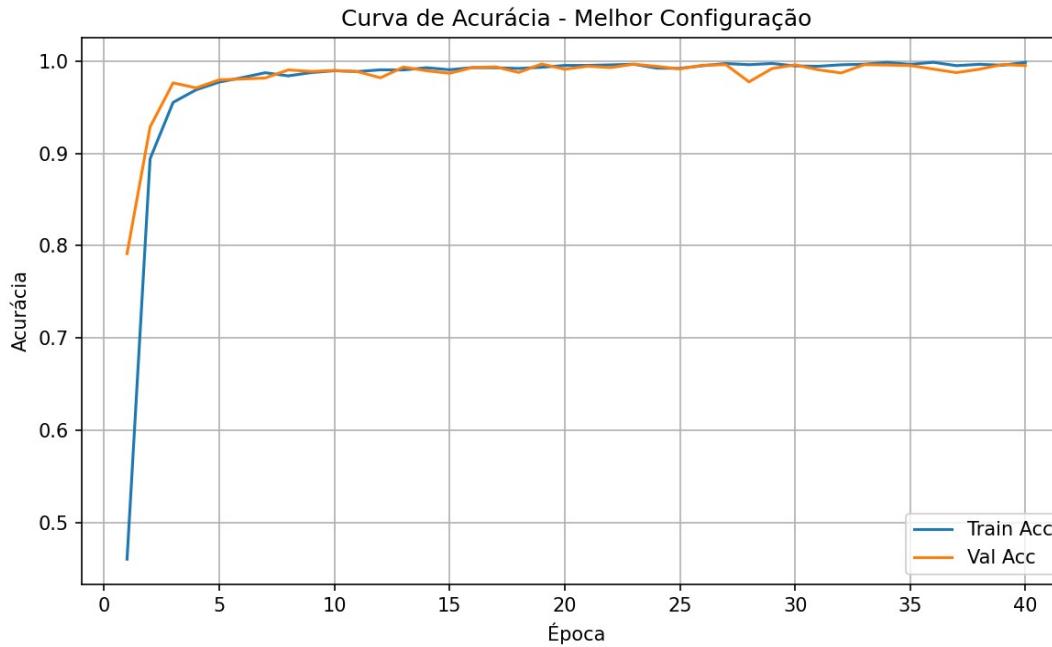
Loss



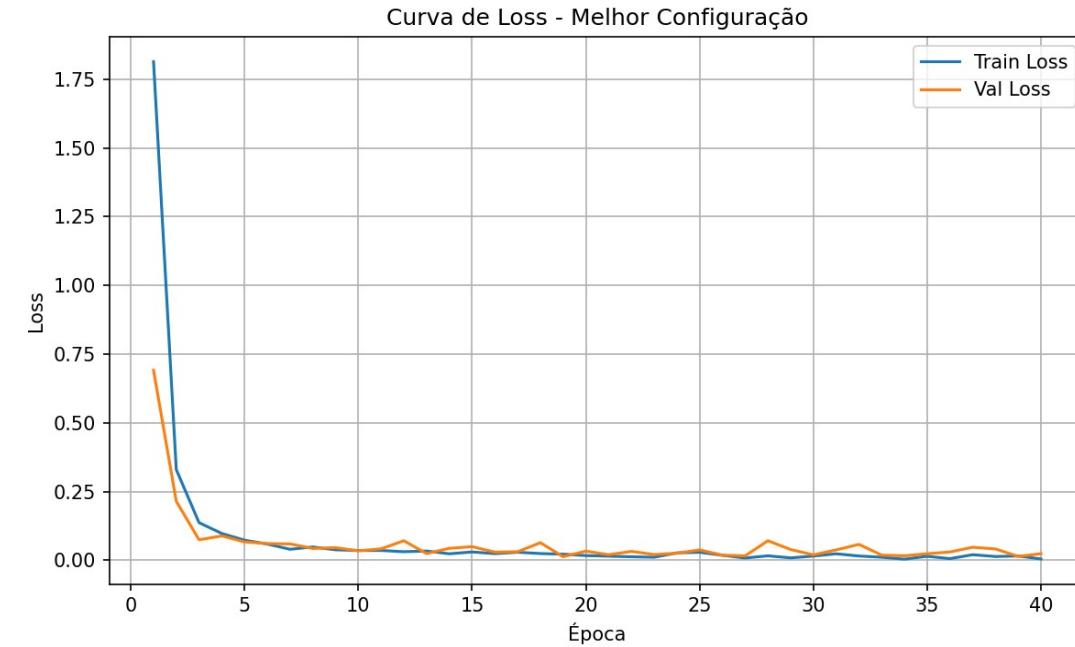
# Classificação de Placas de Trânsito | Resultados

CNN sem técnicas de balanceamento.

Acurácia



Loss



# Classificação de Placas de Trânsito | Resultados

Tabela Comparativa

Modelo	Técnica	Épocas	Acurácia (Validação)	Acurácia (Teste)
MLP	Sem balanceamento	24	94.73%	95.72%
MLP	Subamostragem	24	89.24%	83.90%
MLP	Sobreamostragem	24	67.17%	93.30%
MLP	Subamostragem + Sobreamostragem	24	80.73%	91.74%
CNN	Sem balanceamento	24	99.81%	99.68%

# Classificação de Placas de Trânsito | Resultados

Tabela Comparativa

Modelo	Técnica	Épocas	Acurácia (Validação)	Acurácia (Teste)
MLP	Sem balanceamento	24	94.73%	95.72%
MLP	Subamostragem	24	89.24%	83.90%
MLP	Sobreamostragem	24	67.17%	93.30%
MLP	Subamostragem + Sobreamostragem	24	80.73%	91.74%
CNN	Sem balanceamento	24	99.81%	99.68%

# Classificação de Placas de Trânsito | Resultados

Tabela Comparativa

Modelo	Técnica	Épocas	Acurácia (Validação)	Acurácia (Teste)
MLP	Sem balanceamento	24	94.73%	95.72%
MLP	Subamostragem	24	89.24%	<b>83.90%</b>
MLP	Sobreamostragem	24	<b>67.17%</b>	93.30%
MLP	Subamostragem + Sobreamostragem	24	80.73%	91.74%
CNN	Sem desbalanceamento	24	<b>99.81%</b>	<b>99.68%</b>

- A CNN superou todas as variações da MLP com larga vantagem.
- A CNN foi robusta ao desbalanceamento de classes, não necessitando de técnicas auxiliares.
- Desempenho da CNN é próximo da perfeição para esta tarefa.

# Classificação de Placas de Trânsito | Conclusões

## Extração de Padrões Espaciais:

CNNs são projetadas para preservar e aprender da estrutura 2D (texturas, formas).  
MLPs "achatam" a imagem, perdendo toda a informação espacial.

## Aprendizado Hierárquico:

CNNs aprendem características simples (bordas) e as combinam em padrões complexos (placas).

## Robustez:

CNNs (com *pooling*) têm maior invariância a pequenas translacões e distorções.  
A MLP se mostrou inadequada para problemas de visão computacional.